




ASSISTANT INTELLIGENT DE RECOMMANDATION D'ÉVÉNEMENTS CULTURELS

Projet 7 — Système RAG pour Puls-Events

CONTEXTE & PROBLÉMATIQUE



- Client : Puls-Events, plateforme de découverte d'événements.



- Besoin : Un assistant conversationnel capable de répondre à des questions en langage naturel sur les événements culturels disponibles



- Limites d'un LLM classique :

Connaissance figée à la date d'entraînement
Aucune connaissance des événements locaux
Risque élevé d'hallucinations




Solution retenue : RAG (Retrieval-Augmented Generation)

QU'EST-CE QUE LE RAG ?

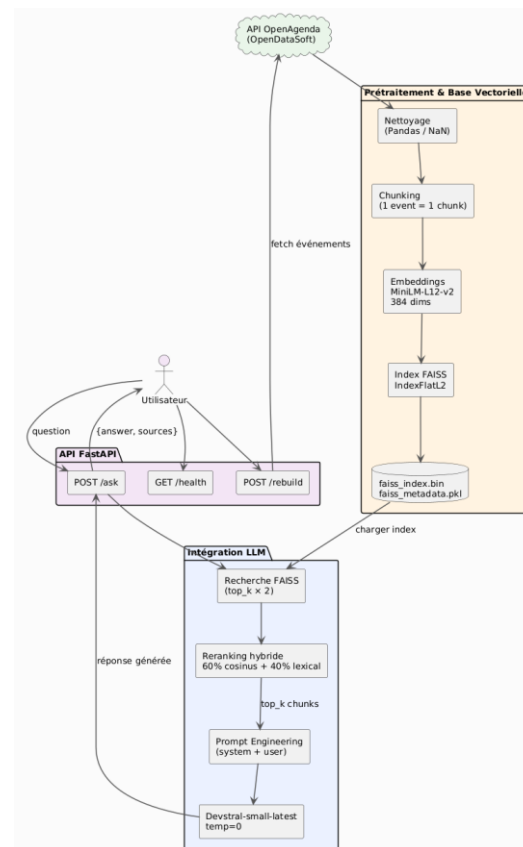
Retrieval-Augmented Generation =
combinaison de la recherche
documentaire et de la génération de
texte

Avantages clés :

- Réponses ancrées dans des données réelles et actualisées
- Traçabilité des sources
- Mise à jour continue via /rebuild




ARCHITECTURE GLOBALE



INTÉGRATION DE LANGCHAIN DANS LE SYSTÈME

- 3 Composants **LangChain** intégrés au système RAG :
 - **ChatMistralAI** : Interface avec le modèle
 - **ChatPromptTemplate** : Gestion des prompts structurés
 - **StrOutputParser** : Extraction des réponses textuelles
- **1. Simplification du code**
 - Pipeline déclaratif avec l'opérateur |
 - Remplace plusieurs appels API manuels par 1 chaîne
- **2. Gestion professionnelle des prompts**
 - Template structurées
 - Injection automatique du contexte + question
- **3. Maintenabilité**
 - Changement de modèle sans réécrire le code
 - Compatible avec l'évaluation automatique



DÉMONSTRATION DE L'API

- POST /ask
 - La question est envoyée au système RAG, qui fournit une réponse pertinente.
- POST /rebuild
 - Reconstruire l'index FAISS en récupérant les derniers événements OpenAgenda
- GET /health
 - Vérification de l'état du système (RAG chargé, API disponible)

ANTI-HALLUCINATION & QUALITÉ

Prompt engineering (7 règles strictes)

- Répondre uniquement à partir des documents fournis
- Si l'information est absente → dire "Je ne sais pas"
- Citer les sources systématiquement
- Pas d'invention de dates, lieux ou prix
- Réponses déterministes, reproductibles
- Réduit la créativité non souhaitée
- Assure que les documents les plus pertinents sont envoyés au LLM

ÉVALUATION RAGAS

Framework : RAGAS — évaluation automatisée de systèmes RAG

Métrique	Score	Signification
Faithfulness	~0.90	Faible taux d'hallucination
Answer Relevancy	~0.65	Pertinence des réponses
Context Precision	~0.60	Qualité des documents récupérés
Context Recall	~0.75	Couverture des informations pertinentes

Analyse :

- Faithfulness élevée → le modèle reste ancré dans les documents
- Context Recall plus faible → certains événements pertinents peuvent être manqués (limitation du volume à 500 événements)
- Les 3 questions hors corpus → correctement identifiées comme "non disponibles"

PERSPECTIVES & AMÉLIORATIONS

Court terme :

- Scheduler automatique (APScheduler / Celery) pour le rebuild périodique
- Authentification JWT sur l'API
- Monitoring Prometheus + Grafana

Moyen terme :

- Recherche hybride avec filtres sur les métadonnées (date, catégorie, lieu)
- Augmenter le volume de données (toutes les villes, pas seulement Lille)
- Mémoire conversationnelle

Long terme :

- Pipeline CI/CD (GitHub Actions → déploiement automatique)
- Interface utilisateur web (React / Next.js)
- Support multimodal (images des événements)